«Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)» (СПбГЭТУ «ЛЭТИ»)

 Направление
 09.03.04 Программная инженерия

 Профиль
 Разработка программно-информационных систем

 Факультет
 КТИ

 Кафедра
 МО ЭВМ

 К защите допустить

1 Sagame oonyemamb

И.о. зав. кафедрой А.А. Лисс

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА БАКАЛАВРА

ТЕМА: РАЗРАБОТКА СРЕДСТВА ВИЗУАЛИЗАЦИИ И МОНИТО-РИНГА КРИМИНАЛЬНОГО КОНТЕНТА ИЗ ТУМАННОЙ ВЫ-ЧИСЛИТЕЛЬНОЙ СРЕДЫ

Студент		подпись	Л.С. Рослова
Руководитель	к.т.н., доцент	подпись	А.А. Лисс
Консультанты	к.т.н., доцент	подпись	А.Ю. Первицкий
		подпись	А.Н. Субботин
	к.т.н.	подпись	М.М. Заславский

Санкт-Петербург 2023

ЗАДАНИЕ

НА ВЫПУСКНУЮ КВАЛИФИКАЦИОННУЮ РАБОТУ

	Утверждаю
	И.о. зав. кафедрой МО ЭВМ
	А.А. Лисс
	«»2023 г.
Студент Рослова Л.С.	Группа 9304
Тема работы: Разработка средст	ва визуализации и мониторинга криминаль-
ного контента из туманной вычи	слительной среды
Место выполнения ВКР: Санкт	г-Петербургский государственный электро-
технический университет «ЛЭТИ	I» им. В.И. Ульянова (Ленина)
Исходные данные (технические	гребования):
OC Windows, OC Linux	
Содержание ВКР:	
Введение, Обзор предметной обл	асти, Функциональные требования,
Архитектура системы, Исследова	ние разработанного решения,
<mark>Доп.раздел БЖД,</mark> Заключение	
Перечень отчетных материалов	: пояснительная записка, иллюстративный
материал.	
Дополнительные разделы: <mark>Безоп</mark> а	асность жизнедеятельности.
П	II DVD
Дата выдачи задания	Дата представления ВКР к защите
«_04_»апреля2023 г.	«9»июня2023 г.
Студент	Л.С. Рослова
Руководитель к.т.н., доцент	А.Ю. Первицкий
Консультант	А.Н. Субботин

КАЛЕНДАРНЫЙ ПЛАН ВЫПОЛНЕНИЯ ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

				2	⁷ тверждан	0
		И.о. 3	3a:	в. кафедрой	і́ МО ЭВМ	1
		_			А.А. Лис	C
		«»			2021 г	- .
Студ	дент	Рослова Л.С.		Группа	9304	
Гема	а работы:	Разработка средства визуализации и м	[O]	ниторинга	криминал	Ь-
ЮГО	контента	из туманной вычислительной среды				
N₂		Наименование работ		Срок	выпол-	
л/п		тилменовиние работ		Н	ения	
1	Обзор ли	тературы по теме работы		04.04	- 03.05	
2	Обзор пр	едметной области		04.05	-06.05	

No	Наименование работ	Срок выпол-
п/п	таимснование работ	нения
1	Обзор литературы по теме работы	04.04 – 03.05
2	Обзор предметной области	04.05 – 06.05
3	Постановка задачи и формализация функциональных требований	06.05 – 10.05
4	Архитектура программной реализации	10.05 – 12.05
5	Результаты разработки/исследование разраб.системы	12.05 – 22.05
6	БЖД	22.05 – 23.05
7	Оформление пояснительной записки	23.05 – 31.05
8	Оформление иллюстративного материала	01.06 – 04.06
9	Предзащита	01.06

Студент		 Рослова Л.С.
Руководитель	к.т.н., доцент	 А.Ю. Первицкий
Консультант		 А.Н. Субботин

РЕФЕРАТ

Пояснительная записка 65 стр., 19 рис., 16 табл., 24 ист.

КРИМИНАЛЬНЫЙ КОНТЕНТ, МОНИТОРИНГ, АНАЛИЗ, ИНТЕР-НЕТ-РЕСУРС, МОДЕЛЬ, НЕЙРОННАЯ СЕТЬ, ТУМАННЫЕ ТЕХНО-ЛОГИИ

Объектом исследования являются интернет-ресурсы, содержащие криминальный контент.

Предметом исследования являются методы анализа контента веб-сайтов с использованием машинного обучения.

Цель работы: разработка архитектуры расширения для браузера анализирующего посещаемый веб-ресурс на криминальный контент с применением средств машинного обучения и с возможностью минимизации задержек при обработке данных.

Результатом данной работы является создание расширение для браузера, которое анализирует изображения на интернет-ресурсе моделями глубокого обучения и предоставляет информацию о том, к какой категории оно относится. Для этого использовалась готовые программные библиотеки, позволяющие строить и обучать нейронной сети с целью автоматической классификации образов. В работе описывается архитектура расширения, состоящая из двух основных компонентов: модуля загрузки изображений и отображения результатов анализа, модуля загрузки и подключения модели к расширению.

ABSTRACT

The result of this work is the creation of a browser extension that analyzes images on an Internet resource with deep learning models and provides information about which category it belongs to. To do this, we used ready-made software libraries that allow us to build and train neural networks in order to automatically classify images. The paper describes the architecture of the extension, consisting of two main components: the module for loading images and displaying analysis results, the module for loading and connecting the model to the extension.

Содержание

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ	. 7
ВВЕДЕНИЕ	8
1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ	.11
1.1 Обработка и анализ изображений	
1.1.1 Возможности обработки изображений моделями машинного обучения	
1.1.2 Нейронные сети для классификации изображений	
VGG-16	
Inception	.14
MobileNetV2	
ResNet50	.14
EfficientNet	.14
1.2 Анализ существующих систем мониторинга криминального контента	.14
1.3 Выводы	.14
ЗАКЛЮЧЕНИЕ (заголовок второго уровня)	.16
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ (заголовок второго уровня)	
ПРИЛОЖЕНИЕ А (заголовок второго уровня)	

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

 $Я\Pi$ – язык программирования;

HTML – стандартизированный язык разметки документов для просморта вебстраниц в браузере;

Датасет – набор данных для обучения нейронной сети;

JSON – текстовый формат обмена данными;

Тензор – обобщение векторов и матриц на более высокие измерения.

Автоэнкодеры - нейронные сети прямого распространения, которые восстанавливают входной сигнал на выходе.

ВВЕДЕНИЕ

Согласно данным из отчёта 'Global Digital 2022'[1] процент интернетпользователей в 2022 году перешёл черту в 62% от населения мира. При этом
каждый имеет возможность выкладывать в сеть новый материал. Особенно
активно в сеть загружаются изображения, которые практически никогда не
проходят проверку на криминальное содержимое перед публикацией. Актуальность расширения для браузера, анализирующего такой материал на криминальное содержание с помощью нейронной сети, обусловлена необходимостью защиты пользователей от нежелательного контента в интернете. В
современном мире существует большое количество сайтов, на которых
имеется деструктивное содержание, такое как порнография, алкоголь, наркотики, оружие и т.д. Этот контент может быть вредным для психического и
эмоционального здоровья пользователей, особенно детей и подростков.

Традиционные методы блокировки нежелательного контента, такие как фильтры URL и списки блокировки сайтов, не всегда эффективны и могут пропустить определенные типы деструктивного материала. Однако использование методов машинного обучения, в том числе нейронных сетей, позволяет более точно и надежно определять деструктивное содержание на изображениях.

Таким образом, разработка расширения для браузера, анализирующего изображения на криминальный контент с помощью нейронной сети, является актуальной задачей, которая может улучшить безопасность пользователей в интернете и предотвратить негативные последствия, связанные с просмотром нежелательного материала.

Цель работы: разработка архитектуры расширения для браузера анализирующего посещаемый веб-ресурс на криминальный контент с применением средств машинного обучения и с возможностью минимизации задержек при обработке данных.

Задачи данной работы:

- 1. Изучение методов и технологий машинного обучения, необходимых для анализа изображений.
- 2. Разработка архитектуры расширения для браузера, которое будет осуществлять анализ посещаемых веб-ресурсов на наличие криминального контента.
- 3. Реализация механизмов, обеспечивающих сбор и анализ данных о посещаемых веб-ресурсах.
- 4. Интеграция средств машинного обучения для обработки и анализа данных на наличие криминального контента.
- 5. Тестирование и оптимизация работы расширения для браузера, с целью повышения точности определения криминального контента и уменьшения ложных срабатываний.

Объектом исследования являются интернет-ресурсы, содержащие криминальный контент.

Предметом исследования являются методы анализа контента веб-сайтов с использованием машинного обучения.

Практическая ценность работы:

- 1. Повышение безопасности пользователей в интернете. Расширение может обнаруживать наличие криминального контента на посещаемых веб-ресурсах, что поможет избежать неприятных ситуаций и предотвратить потенциальные угрозы для пользователей.
- 2. Уменьшение распространения криминального контента в интернете. Расширение может обнаруживать криминальный контент на посещаемых веб-ресурсах и предупреждать пользователей о его наличии. Это может помочь снизить распространение криминального контента в интернете и сделать его менее доступным.
- 3. Упрощение родительского контроля. Родители могут использовать расширение для браузера, чтобы отслеживать посещаемые

их детьми веб-ресурсы и обнаруживать наличие криминального контента на этих ресурсах.

1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Обработка и анализ изображений

Существует множество способов обработки и анализа изображений, включая:

- 1. Преобразование изображений: изменение размера, поворот, перспективная коррекция, цветокоррекция, обрезка и т.д.
- 2. Фильтрация изображений: удаление шума, повышение резкости, фильтры низких и высоких частот, усреднение и т.д.
- 3. Сегментация изображений: разделение изображения на отдельные объекты или регионы, разделение переднего плана и фона, определение контуров и т.д.
- 4. Оптическое распознавание символов (OCR): преобразование текста на изображении в машинно-читаемый текст.
- 5. Классификация изображений: определение объектов, сцен, лиц и т.д. на изображении.
- 6. Детектирование объектов: обнаружение объектов на изображении с помощью методов компьютерного зрения.
- 7. Распознавание лиц: обнаружение и идентификация лиц на изображении.
- 8. Машинное обучение: использование алгоритмов машинного обучения для реализации упомянутых выше методов.

В данной работе рассмотрен последний подход с применением машинного обучения, так как он имеет хорошую скорость обработки данных и высокую точность.

1.1.1 Возможности обработки изображений моделями машинного обучения

Существует несколько подходов к обработке изображений моделями машинного обучения:

- Классификация изображений: подход, при котором изображения разбиваются на классы, каждый из которых соответствует определенной категории. Обычно используются сверточные нейронные сети, которые позволяют автоматически извлекать признаки из изображений.
- Детектирование объектов на изображениях: подход, при котором модель машинного обучения позволяет обнаруживать и выделять объекты на изображении. Для этого используются различные архитектуры нейронных сетей, такие как Faster R-CNN или SSD.
- Сегментация изображений: подход, при котором каждый пиксель изображения относится к определенному классу. Обычно используются семантические сегментационные модели, которые позволяют разделять изображение на отдельные части.
- Генерация изображений: подход, при котором модель машинного обучения может генерировать новые изображения на основе имеющихся данных. Для этого используются генеративно-состязательные сети (GAN), автоэнкодеры и другие модели.
- Реконструкция изображений: подход, при котором модель машинного обучения позволяет восстанавливать недостающие части изображения или улучшать его качество. Для этого используются различные архитектуры нейронных сетей, такие как автоэнкодеры или глубокие сверточные сети.

Все имеющиеся возможности можно объединять друг с другом для решения необходимых задач. Классификация изображений является наиболее подходящим подходом для разрабатываемой системы, так как она предназначено для анализа содержимого веб-ресурсов на наличие криминального контента, в частности на наличие изображений, связанных с алкоголем, наркотиками и т.д. Преимуществом использования данного подхода является способность к обнаружению сложных иерархических зависимостей между признаками изображений.

Для решения задачи обнаружения деструктивного материала необходимо провести классификацию изображений на две категории: "негативный контент" и "не негативный контент". Для этого можно обучить модель машинного обучения на большом количестве изображений, размеченных на две категории. Затем, после обучения, сеть можно интегрировать в расширение браузера, чтобы автоматически сканировать веб-ресурсы на предмет наличия негативного контента.

1.1.2 Нейронные сети для классификации изображений

Нейронные сети для классификации изображений - это одна из наиболее актуальных областей машинного обучения. Они широко применяются в различных областях, таких как компьютерное зрение, медицинская диагностика, робототехника, автономные транспортные средства, контроль качества в производстве и многих других. Для классификации изображений, нейронные сети обучаются на большом наборе данных, размеченных на различные категории. В процессе обучения, модели постепенно определяют характеристики, которые помогают им правильно классифицировать материал.

Существует множество различных видов нейронных сетей, которые используются для классификации изображений. Некоторые из них включают в себя:

- Сверточные нейронные сети (Convolutional Neural Networks, CNN) это наиболее распространенный тип нейронных сетей для классификации изображений. Они специально разработаны для обработки многомерных данных, таких как изображения.
- Рекуррентные нейронные сети (Recurrent Neural Networks, RNN) это тип нейронных сетей, который хорошо подходит для работы с последовательными данными, такими как речь или текст. Они также могут использоваться для классификации изображений с использованием предварительно обученных сверточных нейронных сетей.

• Многослойные персептроны (Multilayer Perceptrons, MLP) - это тип нейронных сетей, который имеет несколько скрытых слоев и может быть использован для классификации изображений.

• Глубокие вероятностные модели (Deep Probabilistic Models) - это класс моделей машинного обучения, который использует вероятностные методы для классификации изображений.

• Автоэнкодеры (Autoencoders) - это нейронные сети, которые могут использоваться для обучения скрытых представлений изображений, которые затем могут быть использованы для классификации изображений.

• Глубокие более широкие сети (Deep Wide Networks) - это тип нейронных сетей, который сочетает в себе свойства глубоких и широких сетей, что позволяет обрабатывать данные более эффективно.

Каждый из этих типов нейронных сетей имеет свои преимущества и недостатки в зависимости от конкретного применения, и выбор наиболее подходящей модели будет зависеть от многих факторов, таких как объем данных и доступность вычислительных ресурсов.

VGG-16

Inception

MobileNetV2

ResNet50

EfficientNet

1.2 Анализ существующих систем мониторинга криминального

контента

1.3 Выводы

Пример основного текста



Рисунок 1 – Пример рисунка

Каждая таблица должна иметь ссылку в тексте (таблица 1).

Таблица 1 – Пример таблицы

Показатель	Единица измерения	Значение
Время работы	сек.	159
Нагрузка на ЦПУ	процент	95
Стоимость работ	тыс. руб.	100

ЗАКЛЮЧЕНИЕ (заголовок второго уровня)

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ (заголовок вто-

рого уровня)

- 1. Обзор Digital 2022 [Электронный ресурс] URL: https://www.web-canape.ru/business/statistika-interneta-i-socsetej-na-2022-god-cifry-i-trendy-v-mire-i-v-rossii/ (дата обращения: 23.12.2022)
- 2. Бобкова, О.В., Давыдов, С.А., Ковалева, И.А., Плагиат как гражданское правонарушение / О.В. Бобкова, С.А. Давыдов, И.А. Ковалева // Патенты и лицензии. -2016. -№ 7. С. 31-37.

3.

ПРИЛОЖЕНИЕ А (заголовок второго уровня)