

**«Санкт-Петербургский государственный электротехнический университет
«ЛЭТИ» им. В.И. Ульянова (Ленина)»
(СПбГЭТУ «ЛЭТИ»)**

Направление	09.03.04 Программная инженерия
Профиль	Разработка программно-информационных систем
Факультет	КТИ
Кафедра	МО ЭВМ

К защите допустить

И.о. зав. кафедрой

А.А. Лисс

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
БАКАЛАВРА**

**ТЕМА: РАЗРАБОТКА СРЕДСТВА ВИЗУАЛИЗАЦИИ И МОНИТО-
РИНГА КРИМИНАЛЬНОГО КОНТЕНТА ИЗ ТУМАННОЙ ВЫ-
ЧИСЛИТЕЛЬНОЙ СРЕДЫ**

Студент		<hr/>	Л.С. Рослова
		<i>подпись</i>	
Руководитель	к.т.н., доцент	<hr/>	А.А. Лисс
		<i>подпись</i>	
Консультанты	к.т.н., доцент	<hr/>	А.Ю. Первицкий
		<i>подпись</i>	
		<hr/>	А.Н. Субботин
		<i>подпись</i>	
	к.т.н.	<hr/>	М.М. Заславский
		<i>подпись</i>	

Санкт-Петербург

2023

ЗАДАНИЕ

Утверждаю

И.о. зав. кафедрой МО ЭВМ

_____ А.А. Лисс

« _____ » 2023 г.

Студент Рослова Л.С.

Группа 9304

Тема работы: Разработка средства визуализации и мониторинга криминального контента из туманной вычислительной среды

Место выполнения ВКР: Санкт-Петербургский государственный электротехнический университет «ЛЭТИ» им. В.И. Ульянова (Ленина)

Исходные данные (технические требования):

OC Windows, OC Linux

Содержание ВКР:

Введение, Обзор предметной области, Функциональные требования,

Архитектура системы, Исследование разработанного решения,

Доп.раздел БЖД, Заключение

Перечень отчетных материалов: пояснительная записка, иллюстративный материал.

Дополнительные разделы: **Безопасность жизнедеятельности.**

Дата выдачи задания

Дата представления ВКР к защите

«_04_»__апреля____2023 г.

«9»__июня__2023 г.

Студент

Л.С. Рослова

Руководитель

К.Т.Н., ДОЦЕНТ

А.Ю. Первицкий

Консультант

А.Н. Субботин

КАЛЕНДАРНЫЙ ПЛАН ВЫПОЛНЕНИЯ ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЫ

Утверждаю
И.о. зав. кафедрой МО ЭВМ
_____ А.А. Лисс
«___» _____ 2021 г.

Студент	Рослова Л.С.	Группа	9304
Тема работы: Разработка средства визуализации и мониторинга криминального контента из туманной вычислительной среды			

№ п/п	Наименование работ	Срок выполнения
1	Обзор литературы по теме работы	04.04 – 03.05
2	Обзор предметной области	04.05 – 06.05
3	Постановка задачи и формализация функциональных требований	06.05 – 10.05
4	Архитектура программной реализации	10.05 – 12.05
5	Результаты разработки/исследование разраб.системы	12.05 – 22.05
6	БЖД	22.05 – 23.05
7	Оформление пояснительной записки	23.05 – 31.05
8	Оформление иллюстративного материала	01.06 – 04.06
9	Предзащита	01.06

Студент		Рослова Л.С.
Руководитель	к.т.н., доцент 	А.Ю. Первицкий
Консультант		А.Н. Субботин

РЕФЕРАТ

Пояснительная записка 65 стр., 19 рис., 16 табл., 24 ист.

КРИМИНАЛЬНЫЙ КОНТЕНТ, МОНИТОРИНГ, АНАЛИЗ, ИНТЕР-
НЕТ-РЕСУРС, МОДЕЛЬ, НЕЙРОННАЯ СЕТЬ, ТУМАННЫЕ ВЫЧИС-
ЛЕНИЯ

Объектом исследования являются интернет-ресурсы, содержащие криминальный контент.

Предметом исследования являются методы анализа контента веб-сайтов с использованием машинного обучения.

Цель работы: разработка архитектуры расширения для браузера анализирующего посещаемый веб-ресурс на криминальный контент с применением средств машинного обучения и с возможностью минимизации задержек при обработке данных.

Результатом данной работы является создание расширение для браузера, которое анализирует изображения на интернет-ресурсе моделями глубокого обучения и предоставляет информацию о том, к какой категории оно относится. Для этого использовались готовые программные библиотеки, позволяющие строить и обучать нейронной сети с целью автоматической классификации образов. В работе описывается архитектура расширения, состоящая из двух основных компонентов: модуля загрузки изображений и отображения результатов анализа, модуля загрузки и подключения модели к расширению.

ABSTRACT

The result of this work is the creation of a browser extension that analyzes images on an Internet resource with deep learning models and provides information about which category it belongs to. To do this, we used ready-made software libraries that allow us to build and train neural networks in order to automatically classify images. The paper describes the architecture of the extension, consisting of two main components: the module for loading images and displaying analysis results, the module for loading and connecting the model to the extension.

Содержание

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ.....	7
ВВЕДЕНИЕ.....	8
1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ.....	11
1.1 Обработка и анализ изображений.....	11
1.1.1 Возможности обработки изображений моделями машинного обучения.....	11
1.1.2 Нейронные сети для классификации изображений.....	13
VGG-16.....	14
Inception.....	14
MobileNetV2.....	14
ResNet50.....	14
EfficientNet.....	14
1.2 Анализ существующих систем мониторинга криминального контента.....	14
1.3 Выводы.....	14
ЗАКЛЮЧЕНИЕ (заголовок второго уровня).....	16
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ (заголовок второго уровня).....	17
ПРИЛОЖЕНИЕ А (заголовок второго уровня).....	18

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

ЯП – язык программирования;

HTML – стандартизированный язык разметки документов для просмотра веб-страниц в браузере;

Датасет – набор данных для обучения нейронной сети;

JSON – текстовый формат обмена данными;

Тензор – обобщение векторов и матриц на более высокие измерения.

Автоэнкодеры - нейронные сети прямого распространения, которые восстанавливают входной сигнал на выходе.

ReLU (Rectified Linear Unit) - это наиболее часто используемая функция активации при глубоком обучении. Данная функция возвращает 0, если принимает отрицательный аргумент, в случае же положительного аргумента, функция возвращает само число.

Свёрточный слой - это основной блок свёрточной нейронной сети. Слой свёртки включает в себя для каждого канала свой фильтр, ядро свёртки которого обрабатывает предыдущий слой по фрагментам (суммируя результаты поэлементного произведения для каждого фрагмента).

Полносвязный слой - этот слой обрабатывает каждый элемент предыдущего слоя, выполняя матричное перемножение этих элементов со своими весами.

Dropout - метод регуляризации искусственных нейронных сетей, предназначен для уменьшения переобучения сети за счет предотвращения сложных коадаптаций отдельных нейронов на тренировочных данных во время обучения.

Пулинг - понижение размерности изображения, применяемой во избежание переобучения модели нейронной сети.

Batch Normalization -

CNN -

Аугментация -

ВВЕДЕНИЕ

Согласно данным из отчёта ‘Global Digital 2022’[1] процент интернет-пользователей в 2022 году перешёл черту в 62% от населения мира. При этом каждый имеет возможность выкладывать в сеть новый материал. Особенно активно в сеть загружаются изображения, которые практически никогда не проходят проверку на криминальное содержимое перед публикацией. Актуальность расширения для браузера, анализирующего такой материал на криминальное содержание с помощью нейронной сети, обусловлена необходимостью защиты пользователей от нежелательного контента в интернете. В современном мире существует большое количество сайтов, на которых имеется деструктивное содержание, такое как порнография, алкоголь, наркотики, оружие и т.д. Этот контент может быть вредным для психического и эмоционального здоровья пользователей, особенно детей и подростков.

Традиционные методы блокировки нежелательного контента, такие как фильтры URL и списки блокировки сайтов, не всегда эффективны и могут пропустить определенные типы деструктивного материала. Однако использование методов машинного обучения, в том числе нейронных сетей, позволяет более точно и надежно определять деструктивное содержание на изображениях.

Таким образом, разработка расширения для браузера, анализирующего изображения на криминальный контент с помощью нейронной сети, является актуальной задачей, которая позволит пользователям защититься от негативного контента на посещаемых веб-ресурсах, а также представляет возможность использования машинного обучения и туманных вычислений для решения задач анализа изображений в реальном времени.

Цель работы: разработка архитектуры расширения для браузера анализирующего посещаемый веб-ресурс на криминальный контент с применением средств машинного обучения и туманных вычислений для минимизации задержек.

Задачи данной работы:

1. Изучение методов и технологий машинного обучения, необходимых для анализа изображений.
2. Разработка архитектуры расширения для браузера, которое будет обращаться к туманным сервисам для анализа изображений на криминальный контент.
3. Реализация механизмов, обеспечивающих сбор и анализ данных о посещаемых веб-ресурсах.
4. Интеграция средств машинного обучения для обработки и анализа данных на наличие криминального контента.
5. Тестирование и оптимизация работы расширения для браузера, с целью повышения точности определения криминального контента и уменьшения ложных срабатываний.

Объектом исследования являются интернет-ресурсы, содержащие криминальный контент.

Предметом исследования являются методы анализа контента веб-сайтов с использованием машинного обучения.

Практическая ценность работы:

1. Повышение безопасности пользователей в интернете. Расширение может обнаруживать наличие криминального контента на посещаемых веб-ресурсах, что поможет избежать неприятных ситуаций и предотвратить потенциальные угрозы для пользователей.
2. Уменьшение распространения криминального контента в интернете. Расширение может обнаруживать криминальный контент на посещаемых веб-ресурсах и предупреждать пользователей о его наличии. Это может помочь снизить распространение криминального контента в интернете и сделать его менее доступным.
3. Упрощение родительского контроля. Родители могут использовать расширение для браузера, чтобы отслеживать посещаемые

их детьми веб-ресурсы и обнаруживать наличие криминального контента на этих ресурсах.

1 ОБЗОР ПРЕДМЕТНОЙ ОБЛАСТИ

1.1 Обработка и анализ изображений

Существует множество способов обработки и анализа изображений, включая:

1. Преобразование изображений: изменение размера, поворот, перспективная коррекция, цветокоррекция, обрезка и т.д.
2. Фильтрация изображений: удаление шума, повышение резкости, фильтры низких и высоких частот, усреднение и т.д.
3. Сегментация изображений: разделение изображения на отдельные объекты или регионы, разделение переднего плана и фона, определение контуров и т.д.
4. Оптическое распознавание символов (OCR): преобразование текста на изображении в машинно-читаемый текст.
5. Классификация изображений: определение объектов, сцен, лиц и т.д. на изображении.
6. Детектирование объектов: обнаружение объектов на изображении с помощью методов компьютерного зрения.
7. Распознавание лиц: обнаружение и идентификация лиц на изображении.
8. Машинное обучение: использование алгоритмов машинного обучения для реализации упомянутых выше методов.

В данной работе рассмотрен последний подход с применением машинного обучения, так как он имеет хорошую скорость обработки данных и высокую точность.

1.1.1 Возможности обработки изображений моделями машинного обучения

Существует несколько подходов к обработке изображений моделями машинного обучения:

- Классификация изображений: подход, при котором изображения разбиваются на классы, каждый из которых соответствует определенной категории. Обычно используются сверточные нейронные сети, которые позволяют автоматически извлекать признаки из изображений.
- Детектирование объектов на изображениях: подход, при котором модель машинного обучения позволяет обнаруживать и выделять объекты на изображении. Для этого используются различные архитектуры нейронных сетей, такие как Faster R-CNN или SSD.
- Сегментация изображений: подход, при котором каждый пиксель изображения относится к определенному классу. Обычно используются семантические сегментационные модели, которые позволяют разделять изображение на отдельные части.
- Генерация изображений: подход, при котором модель машинного обучения может генерировать новые изображения на основе имеющихся данных. Для этого используются генеративно-состязательные сети (GAN), автоэнкодеры и другие модели.
- Реконструкция изображений: подход, при котором модель машинного обучения позволяет восстанавливать недостающие части изображения или улучшать его качество. Для этого используются различные архитектуры нейронных сетей, такие как автоэнкодеры или глубокие сверточные сети.

Все имеющиеся возможности можно объединять друг с другом для решения необходимых задач. Классификация изображений является наиболее подходящим подходом для разрабатываемой системы, так как она предназначена для анализа содержимого веб-ресурсов на наличие криминального контента, в частности на наличие изображений, связанных с алкоголем, наркотиками и т.д. Преимуществом использования данного подхода является способность к обнаружению сложных иерархических зависимостей между признаками изображений.

Для решения задачи обнаружения деструктивного материала необходимо провести классификацию изображений на **две категории: "негативный контент" и "не негативный контент"**. Для этого можно обучить модель машинного обучения на **большом количестве изображений, размеченных на две категории**. Затем, после обучения, сеть можно интегрировать в расширение браузера, чтобы автоматически сканировать веб-ресурсы на предмет наличия негативного контента.

1.1.2 Нейронные сети для классификации изображений

Нейронные сети для классификации изображений - это одна из наиболее актуальных областей машинного обучения. Они широко применяются в различных областях, таких как компьютерное зрение, медицинская диагностика, робототехника, автономные транспортные средства, контроль качества в производстве и многих других. Для классификации изображений, нейронные сети обучаются на большом наборе данных, размеченных на различные категории. В процессе обучения, модели постепенно определяют характеристики, которые помогают им правильно классифицировать материал.

Существует множество различных видов нейронных сетей, которые используются для классификации изображений. Некоторые из них включают в себя:

- Сверточные нейронные сети (Convolutional Neural Networks, CNN) - это наиболее распространенный тип нейронных сетей для классификации изображений. Они специально разработаны для обработки многомерных данных, таких как изображения.
- Рекуррентные нейронные сети (Recurrent Neural Networks, RNN) - это тип нейронных сетей, который хорошо подходит для работы с последовательными данными, такими как речь или текст. Они также могут использоваться для классификации изображений с использованием предварительно обученных сверточных нейронных сетей.

- Многослойные перцептроны (Multilayer Perceptrons, MLP) - это тип нейронных сетей, который имеет несколько скрытых слоев и может быть использован для классификации изображений.
- Глубокие вероятностные модели (Deep Probabilistic Models) - это класс моделей машинного обучения, который использует вероятностные методы для классификации изображений.
- Автоэнкодеры (Autoencoders) - это нейронные сети, которые могут использоваться для обучения скрытых представлений изображений, которые затем могут быть использованы для классификации изображений.
- Глубокие более широкие сети (Deep Wide Networks) - это тип нейронных сетей, который сочетает в себе свойства глубоких и широких сетей, что позволяет обрабатывать данные более эффективно.

Каждый из этих типов нейронных сетей имеет свои преимущества и недостатки в зависимости от конкретного применения, и выбор наиболее подходящей модели будет зависеть от многих факторов, таких как объем данных и доступность вычислительных ресурсов.

1.1.3 VGG-16

VGG16 — модель сверточной нейронной сети, предложенная К. Simonyan и А. Zisserman из Оксфордского университета в статье “Very Deep Convolutional Networks for Large-Scale Image Recognition” [2]. Модель достигает точности 92.7% — топ-5, при тестировании на датасете ImageNet в задаче распознавания объектов на изображении. Этот набор данных состоит из более чем 14 миллионов изображений, принадлежащих к 1000 классам.

Архитектура VGG16 представлена на рисунке 1.

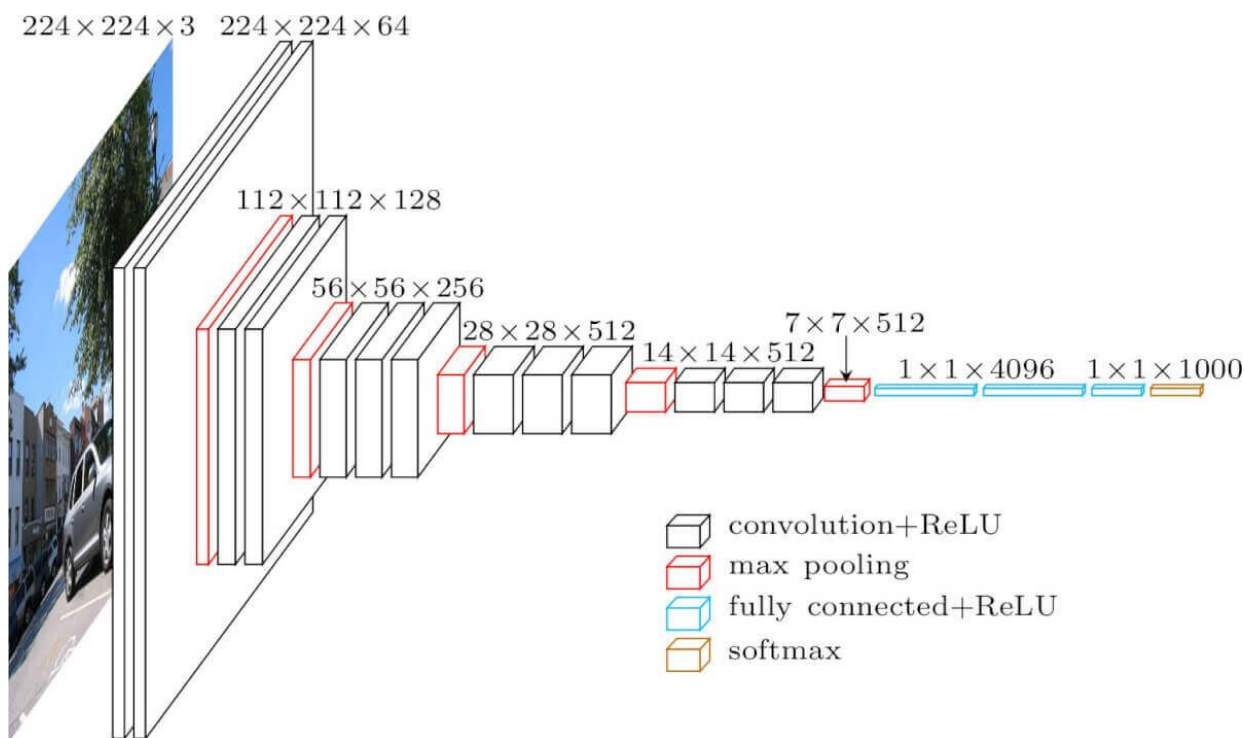


Рисунок 1 - Архитектура VGG16

Нейронная сеть VGG16 состоит из 16 слоев, включая 13 сверточных слоев и 3 полносвязных слоя. Она имеет фиксированный размер входного изображения 224×224 пикселя. Сверточные слои применяют фильтры размером 3×3 и используют функцию активации ReLU. После каждого двух сверточных слоев следует слой максимальной подвыборки размера 2×2 . В конце сети расположены три полносвязных слоя, где последний слой используется для классификации на заданное количество классов. VGG16 имеет более 138 миллионов обучаемых параметров.

1.1.4 InceptionV3

InceptionV3 [3] - это сверточная нейронная сеть, разработанная компанией Google, которая является улучшенной версией модели InceptionV1 и InceptionV2. Она использует специальные блоки, называемые "Inception modules", которые объединяют в себе несколько операций свертки с различными размерами ядер и операций пулинга для извлечения признаков из изображений. Благодаря этому, InceptionV3 имеет высокую точность в задачах

классификации изображений, а также может быть использована для решения задач сегментации и детектирования объектов. InceptionV3 имеет более чем 20 слоев и обучается на большом количестве данных для достижения высокой точности в классификации. Архитектура InceptionV3 представлена на рисунке 2.




Рисунок 2 - Архитектура InceptionV3

Архитектура InceptionV3 состоит из сверточных слоев, блоков "Inception modules" и полносвязных слоев. Внутри "Inception modules" используются несколько операций свертки с различными размерами ядер и операций пулинга. Архитектура имеет более чем 20 слоев и заканчивается полносвязными слоями для классификации. InceptionV3 также использует некоторые техники регуляризации, такие как Dropout и L2 регуляризация, чтобы избежать переобучения.

1.1.5 MobileNetV2

MobileNetV2 [4] - это сверточная нейронная сеть, оптимизированная для мобильных устройств с ограниченными вычислительными ресурсами. Архитектура состоит из нескольких блоков, которые включают в себя последовательность слоев "depthwise separable convolution", которые заменяют стандартные сверточные слои. Схема данной структуры представлена на рисунке 3.




Рисунок 3 - Схема слоя «depthwise separable convolution»

Эти блоки уменьшают количество параметров и операций с плавающей запятой, что позволяет сети работать на мобильных устройствах с ограниченной вычислительной мощностью. MobileNetV2 также использует слои Batch Normalization и ReLU, чтобы ускорить сходимость и обеспечить нелинейность в сети. Она достигает высокой точности на задачах классификации изображений, при этом имея небольшой размер и низкий уровень потребления энергии. Архитектура сети представлена на рисунке 4.

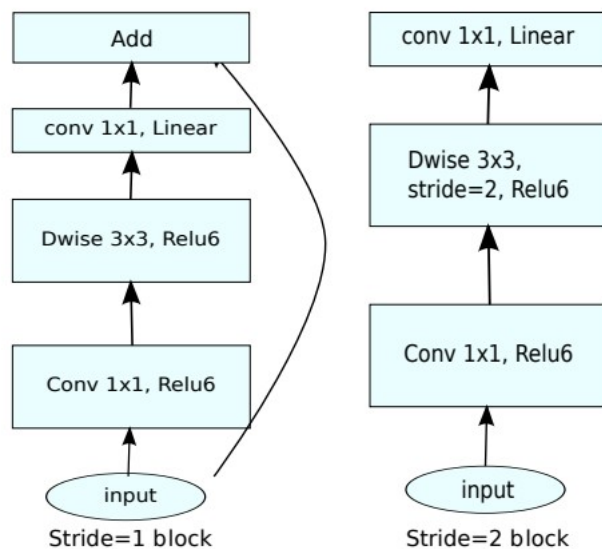


Рисунок 4 - Архитектура MobileNetV2

Блоки включают в себя несколько последовательных операций. Сначала входные данные проходят через сверточный слой с ядром размера 3x3, затем применяется функция активации ReLU6. Затем следует операция "бутстрапинга" - сверточный слой с ядром 1x1, который увеличивает количество каналов признаков. После этого следует еще один сверточный слой с ядром 3x3, снова с функцией активации ReLU6. Благодаря такой конфигурации блоков, MobileNetV2 обладает высокой точностью на задачах классификации изображений при относительно низком количестве параметров и быстродействии.

1.1.6 ResNet50

ResNet — это сокращенное название для Residual Network (дословно — «остаточная сеть») [5]. Это глубокая нейронная сеть, предназначенная для классификации изображений. Её основной принцип состоит в том, чтобы добавить "сквозные" соединения между блоками сверточных слоев, что позволяет сети изучать глубокие представления изображений. Архитектура данной модели представлена на рисунке 5.

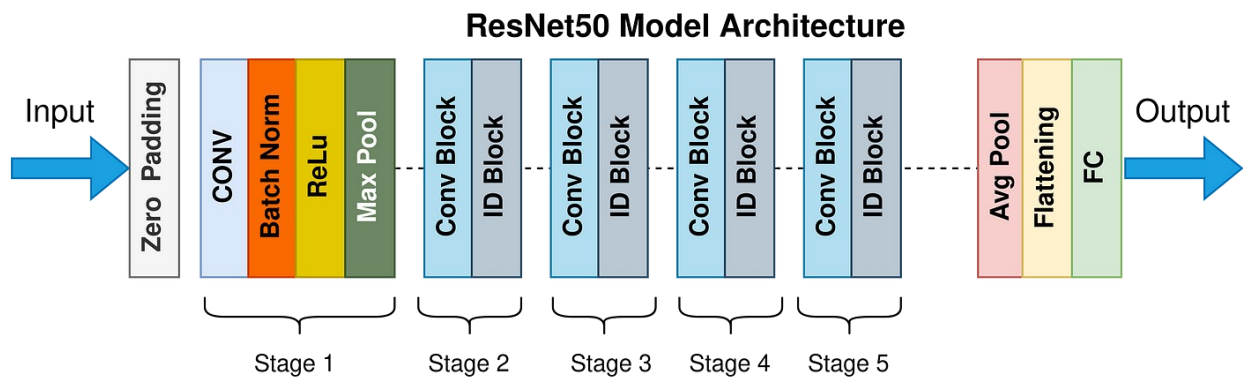


Рисунок 5 - Архитектура ResNet50

Модель состоит из 50 сверточных слоев и нескольких полносвязных слоев. Внутри каждого блока ResNet50 использует сквозные соединения для суммирования входных и выходных данных, чтобы увеличить скорость обучения и улучшить точность предсказаний. ResNet50 также использует сверточные слои с ядрами 1x1 и 3x3, а также групповую нормализацию, чтобы добиться лучшей точности на задачах классификации изображений.

1.1.7 EfficientNet

EfficientNet - это архитектура сверточной нейронной сети и метод масштабирования, который равномерно масштабирует все измерения глубины/ширины/разрешения с использованием составного коэффициента [6]. Разработчики предложили следующие параметры для коэффициента:

- Глубина = 1.20
- Ширина = 1.20
- Разрешение = 1.15

Данные значения не являются константными и пользователь может переопределить их под свои задачи.

Архитектура модели представлена на рисунке 6.

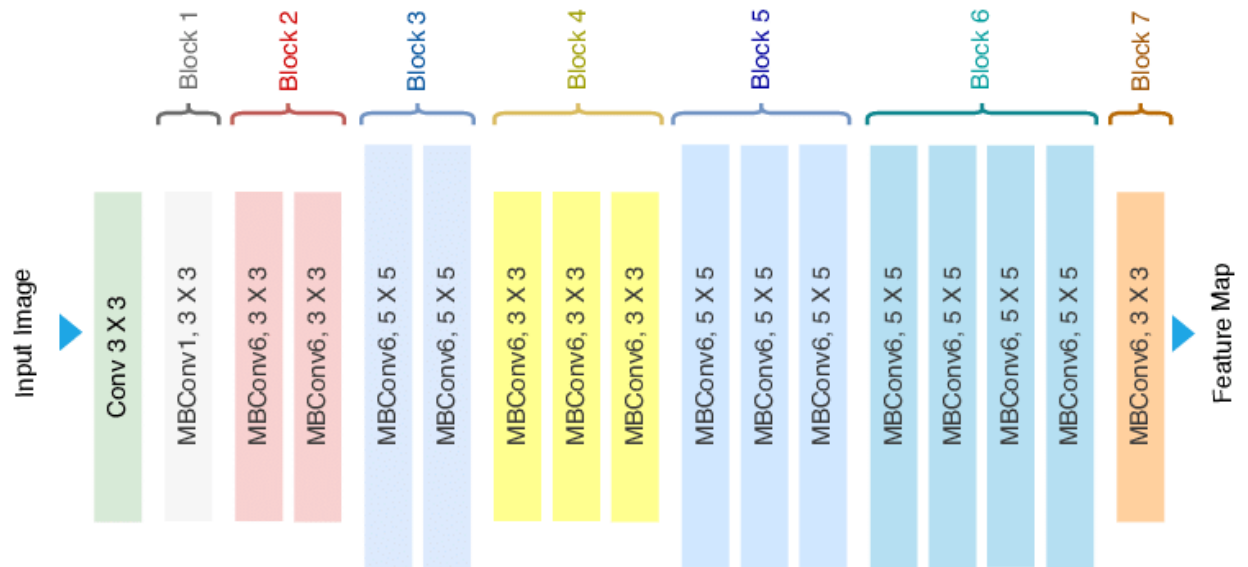


Рисунок 6 - Архитектура EfficientNet

EfficientNet использует блоки Fused MBConv, которые объединяют свертки 3x3 и свертки с ядрами 1x1, что увеличивает скорость обучения и эффективность работы сети. MBConv означает мобильное инвертированное узкое место Convolution (аналогично MobileNetv2). Внутри каждого блока модель использует механизмы подавления сигнала, такие как Squeeze-and-Excitation структуры, которые позволяют сети лучше фокусироваться на важных объектах изображений. Нейронная сеть также использует аугментацию данных и Dropout для уменьшения переобучения и повышения точности.

1.2 Сравнение моделей машинного обучения

После того, как были рассмотрены основные модели машинного обучения для анализа изображений, необходимо сравнить их между собой. Это может помочь выбрать наиболее эффективный и точный алгоритм для решения задачи распознавания изображений, что особенно важно в случае, когда точность классификации является ключевым фактором в принятии решений. Кроме того, сравнение моделей также может помочь в оптимизации производительности и ресурсов, необходимых для работы модели.

Для сравнения рассмотренных нейронных сетей можно использовать следующие критерии:

- Количество параметров: чем меньше параметров, тем более легковесной и быстрой является модель.
- Точность (ассигасу) на тестовых данных: чем выше точность, тем лучше модель распознает изображения.
- Скорость предсказаний (вычисления на новых данных): чем быстрее модель может производить вычисления на новых данных, тем более эффективной она является для реальных приложений.
- Размер модели: чем меньше размер модели, тем меньше занимаемое ею место на диске или в памяти устройства, что может быть важным для некоторых приложений.

Результаты сравнения нейронных сетей по выделенным критериям представлены в таблице 1.

Таблица 1 – Сравнение моделей машинного обучения

Модель	Размер (мб)	Топ-1 точ- ность (%)	Топ-5 точ- ность (%)	Па- рамет- ры (млн)	Время вывода на CPU (мс)	Время вывода на GPU (мс)
VGG16	528	71.3	90.1	138.4	69.5	4.2
InceptionV3	92	77.9	93.7	23.9	42.2	6.9
ResNet50	98	74.9	92.1	25.6	58.2	4.6
MobileNetV2	14	71.3	90.1	3.5	25.9	3.8
EfficientNet	220	85.3	97.4	54.4	1578.9	61.6

Поскольку эта работа направлена на анализ веб-ресурсов на криминальный контент, то показатель точности модели является главным приоритетом. Опираясь на результаты сравнения, можно выделить нейронную сеть EfficientNet как наиболее успешную в классификации изображений. Однако

она также имеет и самое высокое время вывода результата, что можно нивелировать применением туманных вычислительных сред.

1.3 Туманные вычисления

Туманные вычисления (англ. Fog computing) – это модель распределенных вычислений, которая предназначена для обработки данных в облачных сетях ближе к месту их создания и использования [7]. В отличие от классической облачной вычислительной модели, где данные обрабатываются на удаленных серверах, туманные вычисления предлагают обрабатывать данные на более близких к конечным пользователям устройствах (например, на борту транспорта, в здании или на устройствах IoT), что позволяет снизить задержку и увеличить быстродействие приложений. Таким образом, такой подход является дополнением к облачным вычислениям, предлагая новую модель распределенной обработки данных в цифровых сетях.

Архитектура туманной среды представлена на рисунке 7.




Рисунок 7 - Архитектура туманной вычислительной среды

Туманные среды выполняют следующие функции:

- Обеспечение доступа к вычислительным ресурсам и программному обеспечению через сеть Интернет, что позволяет предоставлять вычислительные ресурсы пользователям на удаленных серверах.
- Автоматическое масштабирование ресурсов для удовлетворения изменяющихся требований к вычислениям, что позволяет быстро реагировать на изменения в объеме вычислений.
- Обеспечение безопасности данных и приложений, которые используются в туманных вычислениях, с помощью механизмов шифрования и других мер защиты.
- Управление ресурсами и производительностью, что позволяет более эффективно использовать ресурсы и повышать производительность приложений.
- Расширение возможностей для использования Интернета вещей и других технологий, которые требуют быстрого доступа к большому количеству данных и вычислительной мощности.

Применение туманных сред в разработке расширения для браузера может помочь в следующих аспектах:

- Расширение может быть развернуто на удаленных серверах в туманной среде, что позволяет снизить нагрузку на локальные ресурсы устройства пользователя.
- Туманные вычисления могут предоставить расширению доступ к большим вычислительным ресурсам и библиотекам машинного обучения, которые могут быть недоступны на локальном устройстве пользователя.
- При использовании туманных вычислений расширение может быстро анализировать большое количество данных, что позволяет улучшить качество и точность классификации.

1.4 Вывод по разделу

В данном разделе были рассмотрены различные подходы к обработке изображений, включая классические методы и нейронные сети. Были описаны такие архитектуры нейронных сетей, как VGG16, InceptionV3, MobileNetV2, ResNet50 и EfficientNet. Также в результате сравнения упомянутых моделей была выявлена наиболее точная. Для минимизации её задержек при работе предложен вариант интеграции машинного обучения в туманные вычислительные среды.

Использование машинного обучения для обработки изображений имеет множество преимуществ перед ручной обработкой, включая высокую точность и автоматическую обработку больших объемов данных. Кроме того, применение нейронных сетей может ускорить процесс разработки расширения для браузера, которое будет использоваться для анализа изображений на криминальный контент. Также использование туманных вычислений позволит снизить нагрузку на локальные ресурсы компьютера и обеспечить более быструю и эффективную обработку данных.

2 ФОРМУЛИРОВКА ТРЕБОВАНИЙ К РЕШЕНИЮ И ПО- СТАНОВКА ЗАДАЧИ

2.1 Постановка задачи

2.2 Требования к решению

2.2 Обоснование требований к решению

2.2 Выводы

3 АРХИТЕКТУРА ПРОГРАММНОЙ СИСТЕМЫ

3.1 Используемые технологии

3.2 Архитектура системы

3.2.1 Расширение Chrome

3.2.2 Сервис-вокер

3.2.3 Сервер

3.2.4 Интерфейс расширения

3.3 Выводы

В данном разделе были рассмотрены различные подходы к обработке изображений, включая классические методы и нейронные сети. Были описаны такие архитектуры нейронных сетей, как VGG16, InceptionV3, MobileNetV2, ResNet50 и EfficientNet. Также в результате сравнения упомянутых моделей была выявлена наиболее точная. Для минимизации её задержек при работе предложен вариант интеграции машинного обучения в туманные вычислительные среды.

Использование машинного обучения для обработки изображений имеет множество преимуществ перед ручной обработкой, включая высокую точность и автоматическую обработку больших объемов данных. Кроме того, применение нейронных сетей может ускорить процесс разработки расширения для браузера, которое будет использоваться для анализа изображений на криминальный контент. Также использование туманных вычислений позволит снизить нагрузку на локальные ресурсы компьютера и обеспечить более быструю и эффективную обработку данных.

Пример основного текста

4 ТЕСТИРОВАНИЕ ПРОГРАММНОГО ПРОДУКТА

4.1 Нагрузочное тестирование

4.2 Выводы



Рисунок 1 – Пример рисунка

Каждая таблица должна иметь ссылку в тексте (**таблица 1**).

Таблица 1 – Пример таблицы

Показатель	Единица измерения	Значение
Время работы	сек.	159
Нагрузка на ЦПУ	процент	95
Стоимость работ	тыс. руб.	100

5 БЕЗОПАСНОСТЬ ЖИЗНЕДЕЯТЕЛЬНОСТИ

5.1 Нагрузочное тестирование

5.2 Выводы

ЗАКЛЮЧЕНИЕ (заголовок второго уровня)

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ (заголовок второго уровня)

1. Обзор Digital 2022 [Электронный ресурс] URL: <https://www.webcanape.ru/business/statistika-interneta-i-socsetej-na-2022-god-cifry-i-trendy-v-mire-i-v-rossii/> (дата обращения: 23.12.2022)
2. K. Simonyan, A. Zisserman, Very Deep Convolutional Networks for Large-Scale Image Recognition // conference paper at ICLR 2015 С. 2-3.
3. Документация InceptionV3 [Электронный ресурс] URL: <https://docs.exponenta.ru/deeplearning/ref/inceptionv3.html> (дата обращения: 08.05.2023)
4. M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, L. Chen, MobileNetV2: Inverted Residuals and Linear Bottlenecks // 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) С. 4-7.
5. ResNet (34, 50, 101): «остаточные» CNN для классификации изображений [Электронный ресурс] URL: <https://neurohive.io/ru/vidy-nejrosetej/resnet-34-50-101/> (дата обращения: 08.05.2023)
6. M. Tan, Quoc V. Le, EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks // Proceedings of the 36th International Conference on Machine Learning, ICML 2019 С. 16-24.
7. Jonathan Bar-Magen Numhauser. Fog Computing- Introduction to a new Cloud evolution // Proceedings from the CIES III Congress, January 2012 С. 3-4.
- 8.
9. Бобкова, О.В., Давыдов, С.А., Ковалева, И.А., Плагиат как гражданское правонарушение / О.В. Бобкова, С.А. Давыдов, И.А. Ковалева // Патенты и лицензии. – 2016. – № 7. – С. 31-37.
- 10.

ПРИЛОЖЕНИЕ А (заголовок второго уровня)